

ICESI

UNIVERSIDAD ICESI

Facultad Barberí de Ingeniería, Diseño y Ciencias Aplicadas

Escuela de Tecnología, Diseño e Innovación · Departamento de Computación y Sistemas Inteligentes

ENTREGA EVALUABLE

Análisis Exploratorio de Datos (EDA)

Taller grupal · Analítica de Datos I

Curso: Analítica de Datos I · **Periodo:** 2026-02 · **Grupos:** 001, 002, 003

Docentes: Yasmin Johanna García · Pablo Cruz Martínez

Fecha de entrega: Lunes 8 de septiembre de 2026 · **Plataforma:** SAMAN

1. Presentación del taller

Durante las últimas sesiones aprendieron a **explorar**, **limpiar** y **analizar** datos con Pandas, y en el Laboratorio 3 recorrimos un flujo completo de EDA sobre el dataset de ventas. Ahora es el momento de **aplicar todo lo aprendido de forma autónoma** sobre un dataset nuevo.

Esta actividad es la primera entrega evaluable donde ustedes **eligen el dominio** a analizar (dentro de una lista curada) y toman decisiones sobre cómo abordar el análisis. Es una oportunidad para desarrollar el criterio del analista: no solo *saber hacer*, sino *saber decidir qué hacer y por qué*.

Objetivos de aprendizaje

- Aplicar de forma **autónoma** un flujo completo de EDA sobre datos reales.
- Tomar decisiones justificadas sobre limpieza y transformación de datos.
- Seleccionar las **visualizaciones adecuadas** para cada tipo de variable y para cada pregunta de análisis.
- Interpretar matrices de correlación y análisis multivariados.
- Comunicar hallazgos técnicos como **insights de negocio accionables**.
- Trabajar colaborativamente usando notebooks Jupyter con narrativa profesional.

Resumen de la entrega

Formato de trabajo:	Grupos de 3 a 4 estudiantes
Entregable:	Un único notebook Jupyter .ipynb
Fecha límite:	Lunes 8 de septiembre de 2026, 23:59
Plataforma:	SAMAN
Peso:	Parte del componente Entregas (15% de la nota final)
Política IAG:	Nivel 3 — uso permitido con declaración de transparencia

Cómo abordar el trabajo

El taller está estructurado en **tres pasos**:

- 1. Paso 1 — Seleccionar dataset:** elegir uno de la lista curada y justificar la elección.
- 2. Paso 2 — Realizar el EDA:** desarrollar todas las secciones del análisis en un notebook narrado.
- 3. Paso 3 — Entregar:** subir el notebook a SAMAN antes de la fecha límite, siguiendo la convención de nombres.

2. Paso 1 · Selección del dataset

Cada grupo debe elegir **uno** de los seis datasets curados a continuación. La lista está diseñada para ofrecer variedad de dominios y de tipos de análisis posibles.

¿Cómo elegir bien? No elijan el dataset que "suene fácil". Elijan el que **les despierte curiosidad**: preguntarán mejor a los datos si el tema les importa. Los seis datasets están certificados como **ricos para EDA** (mezcla de variables numéricas, categóricas y temporales, tamaño manejable, con "mugre" real).

Regla de oro: dos grupos del mismo salón **no pueden** elegir el mismo dataset. La asignación es por orden de llegada — coordinen con el docente el registro del grupo y dataset elegido antes de comenzar.

Los seis datasets curados

01

Netflix — Películas y Series

ENTRETENIMIENTO

Catálogo completo de películas y series disponibles en Netflix, con metadatos ricos como país de origen, año de lanzamiento, categorización por género y rating.

TAMAÑO

~8,800 filas · 12 columnas

VARIABLES CLAVE

`type` , `title` , `director` , `country` , `date_added` , `release_year` , `rating` ,
`duration` , `listed_in` , `description`

PREGUNTAS DE ANÁLISIS SUGERIDAS

- ¿Cómo ha evolucionado el catálogo de Netflix en los últimos 10 años?
- ¿Qué países producen más contenido? ¿Series o películas?
- ¿Hay géneros dominantes? ¿Cómo se distribuyen por rating?

ENLACE

<https://www.kaggle.com/datasets/shivamb/netflix-shows>

02

Sinistros Viales Bogotá

COLOMBIA · SOCIAL

Base oficial de la Secretaría Distrital de Movilidad con todos los accidentes de tránsito registrados en Bogotá. Contexto local de alto impacto social — ideal para hacer análisis con propósito público.

TAMAÑO

Miles de registros · 15+ columnas (recomendado filtrar por año, ej. 2023)

VARIABLES CLAVE

fecha, hora, localidad, gravedad, clase, tipo_vehiculo, numero_victimas, coordenadas

PREGUNTAS DE ANÁLISIS SUGERIDAS

- ¿En qué horas y días de la semana ocurren más siniestros?
- ¿Qué localidades concentran los eventos más graves?
- ¿Qué tipo de actor vial está más involucrado? (peatones, motociclistas, etc.)

ENLACE

<https://www.datos.gov.co/en/dataset/Anuario-de-Siniestralidad-Vial-Bogot-D-C-/ecpz-jhmd>

03

Spotify — Canciones populares

MÚSICA · AUDIO

Metadatos y *audio features* (danceability, energy, valence, tempo, loudness, etc.) de miles de canciones populares. Excelente para practicar análisis con muchas variables numéricas continuas y matriz de correlaciones robusta.

TAMAÑO

~10,000 filas · 15+ columnas

VARIABLES CLAVE

artist, track, year, genre, popularity, danceability, energy, valence, tempo, loudness, duration_ms

PREGUNTAS DE ANÁLISIS SUGERIDAS

- ¿Qué audio features están más correlacionadas con la popularidad?
- ¿Cómo han cambiado los estilos musicales por década?
- ¿Es diferente el patrón por género musical?

ENLACE

<https://www.kaggle.com/datasets/joebeachcapital/top-10000-spotify-songs-1960-now>

04

Global Video Game Sales

VIDEOJUEGOS · COMERCIAL

Ventas globales de videojuegos por título, plataforma, género y año, desglosadas por región (Norte América, Europa, Japón y otras). Ideal para análisis temporal, comparación regional y detección de tendencias.

TAMAÑO

~16,500 filas · 11 columnas

VARIABLES CLAVE

Name , Platform , Year , Genre , Publisher , NA_Sales , EU_Sales , JP_Sales , Other_Sales , Global_Sales

PREGUNTAS DE ANÁLISIS SUGERIDAS

- ¿Cómo han evolucionado las ventas globales a lo largo de las décadas?
- ¿Qué plataformas dominan cada región geográfica?
- ¿Existen preferencias de género distintas entre regiones?

ENLACE

<https://www.kaggle.com/datasets/gregorut/videogamesales>

05

Airbnb Listings

TURISMO · ECONOMÍA

Datos de listings de Airbnb para una ciudad a elección (Nueva York, Barcelona, Bogotá, Ciudad de México, etc.). Fuente independiente de investigación urbana con datos geográficos, precios, tipos de alojamiento y reseñas.

TAMAÑO

Varía por ciudad · miles a decenas de miles de filas · 15+ columnas

VARIABLES CLAVE

name , neighbourhood , latitude , longitude , room_type , price , minimum_nights , number_of_reviews , availability_365

PREGUNTAS DE ANÁLISIS SUGERIDAS

- ¿Qué barrios son más caros? ¿Qué factores explican el precio?
- ¿Hay concentración geográfica de ciertos tipos de alojamiento?
- ¿Cómo se relacionan disponibilidad, precio y número de reseñas?

ENLACE

<http://insideairbnb.com/get-the-data/>

06

World Happiness Report

SOCIAL · INTERNACIONAL

Índice mundial de felicidad publicado por la ONU, con puntajes por país en dimensiones como PIB per cápita, apoyo social, expectativa de vida saludable, libertad, generosidad y percepción de corrupción. Excelente para análisis comparativo internacional y correlaciones sólidas.

TAMAÑO

~150 países × varios años (~1,500 filas) · 9-12 columnas

VARIABLES CLAVE

Country, Region, Year, Happiness_Score, GDP_per_Capita, Social_Support, Life_Expectancy, Freedom, Generosity, Corruption

PREGUNTAS DE ANÁLISIS SUGERIDAS

- ¿Qué factores están más correlacionados con la felicidad?
- ¿Cómo se comparan las regiones del mundo? ¿Dónde queda Colombia?
- ¿Ha cambiado el ranking mundial en los últimos años?

ENLACE

<https://www.kaggle.com/datasets/unsdsn/world-happiness>

3. Paso 2 · Contenido mínimo del análisis

El notebook debe organizarse en las siguientes secciones. **Todas son obligatorias**, aunque su profundidad debe ajustarse a la naturaleza del dataset elegido (por ejemplo, si no hay variable temporal, ese análisis puede omitirse justificando).

Secciones del notebook

SECCIÓN 1 · PRESENTACIÓN Y CONTEXTO

- Título del análisis, integrantes del grupo, dataset elegido y justificación de la elección (2-3 líneas).
- 3-5 **preguntas de análisis** que guiarán el trabajo (adaptadas del dataset o propias).

SECCIÓN 2 · CARGA Y EXPLORACIÓN INICIAL

- Importar librerías (Pandas, NumPy, Matplotlib, Seaborn) y cargar los datos.
- Reportar dimensiones, tipos de datos y primeras filas.

SECCIÓN 3 · LIMPIEZA Y PREPARACIÓN MÍNIMA

- Diagnóstico de faltantes y duplicados.
- Corrección de tipos (fechas, numéricos mal codificados, etc.).
- Tratamiento justificado de valores faltantes (imputar, descartar, marcar).
- Creación de **variables derivadas** útiles para el análisis (mes, año, día de la semana, categorías agrupadas, etc.).

SECCIÓN 4 · ANÁLISIS UNIVARIADO

- **Numéricas:** histograma con KDE, boxplot, medidas de tendencia y forma (media, mediana, asimetría).
- **Categorías:** countplot, frecuencia absoluta y relativa, identificación de categorías dominantes.

SECCIÓN 5 · ANÁLISIS BIVARIADO

- Al menos **dos** análisis *categorica* × *numérica* (boxplot condicionado, barplot agregado, violinplot).
- Al menos **un** análisis *categorica* × *categorica* (crosstab + heatmap).

SECCIÓN 6 · ANÁLISIS MULTIVARIADO Y CORRELACIONES

- **Matriz de correlación de Pearson** con heatmap para las variables numéricas.
- Interpretación de los pares más correlacionados y de los que sorprenden.
- Al menos un scatter plot con **hue** para explorar relaciones trivariadas.

SECCIÓN 7 · ANÁLISIS TEMPORAL (SI APLICA)

- Evolución de una métrica clave a lo largo del tiempo.
- Detección de patrones estacionales o tendencias.

SECCIÓN 8 · SÍNTESIS DE HALLAZGOS

- Mínimo **5 insights de negocio** claramente redactados, cada uno respaldado por el gráfico o dato que lo evidencia.
- Cierre con conclusiones y recomendaciones para un tomador de decisiones del dominio.

Regla del "narrativa integrada": cada gráfico debe estar precedido por una celda de markdown explicando **qué pregunta responde**, y seguido por otra celda de markdown con **la interpretación del resultado**. Un notebook sin narrativa no es un análisis: es un cuaderno de código.

4. Paso 3 · Formato de entrega y rúbrica

Cómo entregar

- **Un solo notebook** en formato `.ipynb` con todas las celdas ya ejecutadas (que se vean las salidas y gráficos).
- **Convención de nombre del archivo:** `EDA_Grupo##_Dataset.ipynb`
Ejemplos: `EDA_Grupo03_Netflix.ipynb` , `EDA_Grupo07_Airbnb.ipynb`
- Incluir al inicio del notebook los **nombres completos y códigos** de todos los integrantes del grupo.
- Subir **un único integrante por grupo** a SAMAN. El resto queda en copia en la sección de comentarios.

Antes de subir: reinicien el kernel del notebook y ejecuten *todas* las celdas desde cero (**Restart Kernel and Run All**). Un notebook que no corre de arriba a abajo pierde puntos automáticamente.

Rúbrica de evaluación

Criterio	Qué se evalúa	
Selección y contexto	Justificación de la elección del dataset, preguntas de análisis claras y pertinentes, presentación del grupo.	10%
Limpieza y preparación	Diagnóstico completo, tratamiento justificado de faltantes/duplicados, corrección de tipos, creación de variables derivadas útiles.	15%
Análisis univariado	Cobertura de variables numéricas y categóricas, elección adecuada de visualizaciones, cálculo e interpretación de medidas descriptivas.	15%
Análisis bivariado	Variedad de cruces (cat × num, cat × cat), uso de visualizaciones apropiadas, lectura crítica de los patrones observados.	15%
Multivariado y correlaciones	Matriz de correlación bien construida e interpretada, exploración de relaciones no obvias, uso adecuado de hue para trivariadas.	15%
Insights y comunicación	Calidad de los hallazgos, respaldo con evidencia visual, redacción en lenguaje de negocio, conclusiones accionables.	15%
Calidad del notebook	Narrativa integrada (markdown + código + interpretación), organización por secciones, gráficos legibles con títulos y ejes, código limpio y comentado.	10%
Declaración IAG	Declaración honesta y detallada del uso de herramientas de IA generativa según política del curso (ver siguiente sección).	5%
TOTAL		100%

5. Política de uso de IA generativa

Esta entrega se rige por la **Política Nivel 3** del curso: se permite el uso de herramientas de inteligencia artificial generativa (ChatGPT, Claude, Gemini, Copilot, etc.) para apoyar el trabajo, siempre y cuando se cumplan las siguientes condiciones:

- 1. Declaración transparente:** incluir al final del notebook una sección titulada *"Declaración de uso de IA generativa"* que especifique qué herramientas se usaron, para qué tareas, y cómo se validaron o modificaron sus resultados.
- 2. El pensamiento crítico es del grupo:** las **interpretaciones** y **conclusiones** deben ser producto de la reflexión del equipo, no copia literal de una respuesta de IA. La IA puede sugerir enfoques; el análisis lo hacen ustedes.
- 3. Todo el código debe ser comprendido:** si alguien del grupo no puede explicar una celda de código en clase, esa celda se descuenta.

Recomendación: usen la IA como un compañero de aprendizaje, no como un reemplazo. Pregúntenle "por qué", "qué otras opciones hay", "qué mejorarías de esto". Ese diálogo genera más aprendizaje que pedirle el trabajo hecho.

6. Checklist final antes de entregar

Verifiquen punto por punto

- ☐ Todos los integrantes están listados al inicio del notebook con nombre y código.
- ☐ El dataset elegido está registrado con el docente (para no duplicar entre grupos).
- ☐ El notebook incluye las 8 secciones obligatorias.
- ☐ La matriz de correlaciones está presente y correctamente interpretada.
- ☐ Cada gráfico tiene título, ejes etiquetados y una interpretación en markdown.
- ☐ Se identificaron mínimo 5 insights de negocio con evidencia.
- ☐ El notebook corre de arriba a abajo sin errores tras un **Restart and Run All**.
- ☐ Se incluyó la declaración de uso de IA generativa al final.
- ☐ El archivo se nombró como **EDA_Grupo##_Dataset.ipynb**.
- ☐ Se subió a SAMAN antes del **lunes 8 de septiembre a las 23:59**.

¡Éxitos con el análisis! Este es su primer trabajo autónomo de EDA — disfruten el proceso de dejarse sorprender por los datos. Cualquier duda técnica o de contenido, escríbannos por Moodle antes del jueves de esta semana para tener tiempo de acompañarlos.